
Neuronové sítě pro klasifikaci detekovaných částic ve řídkých energetických maticích

Technická poznámka nad přiloženými daty, screenshoty a současnou vědeckou literaturou

Vstupní materiál: `matrix_dump_0001.zip` + **Vypracováno:** 2. dubna 2026
screenshoty `raw/DBSCAN`

Abstrakt

Tento dokument shrnuje, jak prakticky postupovat při klasifikaci detekovaných částic z řídkých matic, v nichž nenulové prvky nesou kalibrovanou energii a každá matice má připojená časová metadata. Základní jednotkou dumpu je jedna řídká matice 256×256 ; více matic se stejným `sample` tvoří přirozený časový blok a jsou odlišeny hodnotou `set_index`. Z dodaného `matrix_dump_0001.zip` jsem naparsoval 198 matic ve 40 blocích `sample` (78 až 117). Index `sample` roste po 1, zatímco absolutní čas `acq_unix` mezi sousedními bloky roste přesně o 2 s. V jednom `sample` je 1 až 6 paralelních matic, typicky 5; všechny v rámci téhož `sample` sdílejí shodné časové metadata.

Na úrovni jednotlivých pixelů nejde o obraz v běžném kamerovém smyslu, ale o mřížku detektorových buněk, kde hodnota pixelu představuje kalibrovanou energii v dané buňce. Data jsou velmi řídká: průměrně pouze 1.45 % buněk je nenulových a celý dump obsahuje 187 771 aktivních pixelů. To silně favorizuje metody, které zachovávají sparsity a pokud možno neztrácí časovou informaci prostým sečtením rámců.

Z hlediska cílové úlohy doporučuji oddělit: (i) denoising/hit filtering, (ii) clustering nebo instance segmentaci, (iii) klasifikaci clusterů či stop a případně (iv) asociaci přes čas nebo více pohledů. Pro rychlý start doporučuji hybridní postup *DBSCAN + klasifikátor clusterů*. Pro silnější model, který je dobře sladěný s takto řídkými daty, je nejperspektivnější reprezentace aktivních hitů jako množiny bodů nebo grafu a použití point-set/GNN architektur. Pokud je k dispozici hit-level pravda ze simulace, nejsilnějším směrem je dnes naučené klastrování typu *object condensation*, které umí v jednom kroku clustering i klasifikaci.

Hlavní doporučení v jedné stránce

1. **Nejprve přesně popsat data a cílový produkt.** U těchto dat je potřeba oddělit samotné měření (řídce energetické matice) od toho, co z něj chceme dopočítat: cluster, stopu, třídu částice, nebo jen event-level statistiku.
2. **Neztrácet spazitu.** Při průměrné obsazenosti pouze 1.45 % je plně hustá reprezentace celého snímku výpočetně nevhodná, zejména pokud budete později přidávat čas nebo více pohledů.
3. **DBSCAN ponechat jako baseline a bootstrap.** Je výborný jako interpretable baseline, generátor region proposals a zdroj vysokodůvěrných pseudo-štítků, ale sám o sobě řeší jen clustering a špatně zachází s proměnlivou hustotou, překryvy a časem.
4. **První rozumný produkční cíl je klasifikace clusterů.** Pro současný workflow je nej přirozenější pipeline “raw hit map $\rightarrow$ clustering $\rightarrow$ cluster-level klasifikace a confidence”.
5. **Nejsilnější kandidát pro střednědobý vývoj: point-set/GNN model.** Vstupem je seznam aktivních hitů se znaky $(x, y, \log(1 + E), t, \Delta t, \text{set_index})$; výstupem je třída clusteru, případně současně i instance segmentace.
6. **Pokud máte hit-level truth ze simulace, mířit na object condensation.** Tento směr dnes patří k nejrelevantnějšímu SOTA pro detektorová data s neznámým počtem objektů [Kieseler, 2020, Qasim et al., 2021, Garcia et al., 2026].

1 Přesná interpretace dodaných měřených dat

Než má smysl bavit se o neuronové síti, je nutné přesně vymezit, co je v dumpu přímo změřeno a co je až naše pracovní interpretace. Z dodaného souboru lze s jistotou říci, že elementární jednotkou je jedna řádková matice 256×256 s kalibrovanou energií v nenulových pixelech. Více matic se stejným `sample` tvoří přirozený časový blok; uvnitř tohoto bloku sdílejí identická časová metadata a liší se pouze hodnotou `set_index`. Naopak bez externí dokumentace zatím nelze s jistotou tvrdit, zda `set_index` znamená různé senzory, vrstvy, kanály, podsímkové nebo různé pohledy téhož děje.

1.1 Jak vypadá jedna položka v dumpu

Soubor `matrix_dump_0001.zip` obsahuje jediný textový soubor `matrix_dump_0001.txt`. Ten je tvořen posloupností 198 záznamů; každý záznam je v textu uveden prefixem tvaru `sN`, kde hodnota N přesně odpovídá `set_index` následujícího JSON objektu. Jedna položka v dumpu má pozorované schéma shrnuté v tabulce 1.

Tabulka 1: Schéma jedné položky v dumpu, tak jak je lze vyčíst přímo z dat.

Pole	Pozorovaný typ	Co lze říci s jistotou
textový prefix <code>sN</code>	externí tag	delimituje záznam v textovém dumpu; <i>N</i> se shoduje s <code>set_index</code> a není součástí vlastního JSON obsahu
<code>sample</code>	celé číslo	index časového bloku v rámci dumpu; hodnoty 78 až 117, sousední bloky se liší o 1
<code>set_index</code>	celé číslo	index paralelní matice uvnitř daného <code>sample</code> ; hodnoty 1 až 6
<code>acq_unix</code>	reálné číslo [s]	absolutní Unix timestamp; uvnitř jednoho <code>sample</code> je shodný pro všechny matice, mezi sousedními <code>sample</code> roste přesně o 2 s
<code>hw_t0_ns</code>	reálné číslo [ns]	interní časová veličina společná všem maticím daného <code>sample</code> ; bez schématu ji nelze fyzikálně přesněji pojmenovat
<code>hw_t_proc_ns</code>	reálné číslo [ns]	druhá interní časová veličina společná všem maticím daného <code>sample</code> ; pozorovaně leží přibližně mezi 206 a 250 ms
<code>matrix.shape</code>	dvojice celých čísel	vždy [256,256]
<code>matrix.nnz</code>	celé číslo	počet aktivních pixelů v dané matici
<code>matrix.entries</code>	seznam trojic	řídký seznam nenulových pixelů ve tvaru { <i>x</i> , <i>y</i> , <i>energy</i> }
<i>x</i> , <i>y</i>	celé číslo	souřadnice pixelu v rozsahu 0 až 255
<i>energy</i>	kladné reálné číslo	kalibrovaná energie uložená v aktivním pixelu

Co víme přímo z dumpu a co je zatím jen pracovní interpretace

Přímo z dumpu víme: že každá položka je řídká energetická matice 256×256 ; že `sample` je přirozený časový klíč; že více matic v témže `sample` sdílí stejný `acq_unix`, `hw_t0_ns` a `hw_t_proc_ns`; a že samotný obsah matice je seznam aktivních pixelů s kladnou energií.

Pracovní interpretace, kterou je potřeba potvrdit dokumentací: že `set_index` představuje různé pohledy, vrstvy nebo kanály jednoho děje; že `hw_t_proc_ns` je délka integračního či processing okna; a že `hw_t0_ns` je časový offset uvnitř širšího akvizičního cyklu. Tyto interpretace jsou rozumné, ale nejsou přímo dokazatelné z dumpu samotného.


1.2 Časová organizace: co je jeden krok a co je v něm obsaženo

Přirozenou časovou jednotkou v dumpu je `sample`. V souboru je 40 unikátních hodnot `sample` od 78 do 117; index tedy roste po 1. Absolutní čas `acq_unix` mezi sousedními `sample` roste přesně o 2 s, takže dump pozorovaně pokrývá 78 s akviziční historie. To je důležitý detail: **časový krok v indexu sample je 1, zatímco časový krok ve fyzickém čase acq_unix je 2 s**. Jinými slovy, `sample` je pořadový index bloku a `acq_unix` je jeho absolutní časová kotva.

Uvnitř jednoho `sample` je přítomno 1 až 6 matic odlišených `set_index`. Rozdělení je následující: 31 bloků obsahuje 5 matic, 5 bloků obsahuje 6 matic, 3 bloky obsahují 4 matice a jeden blok obsahuje jen jedinou matici. Prakticky to znamená, že `sample` je vhodná úroveň pro časové dělení dat a `set_index` je vhodná úroveň pro dělení na paralelní podrepräsentace téhož časového kroku. Většina bloků obsahuje `set_index=1` až 5; `set_index=6` se v dumpu objevuje jen v blocích 86, 90, 93, 101

a 104. Na začátku a na konci dumpu navíc některé `set_index` chybí, takže jde zřejmě o výřez z delší sekvence, nikoli o kompletní uzavřený běh.

Z časových polí je dále pozorovatelné, že `hw_t_proc_ns` leží přibližně mezi 206.3 ms a 250.0 ms, medián je 249.3 ms. To silně naznačuje nějaké interní akviziční nebo processing okno uvnitř hrubší dvousekundové kadence `acq_unix`. Pole `hw_t0_ns` leží mezi 1.6 μ s a 4.24 ms, medián je zhruba 1.01 ms; bez dokumentace jej ale doporučuji chápat pouze jako pomocné časové metadata, ne jako přímo fyzikální veličinu s jednoznačným významem.



Obrázek 1: Časová organizace dumpu. Nahoře je vidět lineární vztah mezi `sample` a relativním časem `acq_unix`; čísla nad body udávají, kolik matic se v daném `sample` nachází. Dole je přítomnost jednotlivých `set_index` v čase.

Praktický důsledek pro modelování je zásadní: pokud budete chtít využít čas, přirozená struktura dat není “jedna 2D matice”, ale spíše *časový blok sample obsahující několik paralelních řídkých matic*. To favorizuje multi-view nebo set-based reprezentaci nad prostým sečtením všeho do jedné 2D mapy.

1.3 Co přesně znamená pixel

Každá matice má tvar 256×256 a je uložena ve sparse formátu. To znamená, že v textu jsou uvedeny pouze nenulové pixely; všechny chybějící souřadnice je třeba interpretovat jako nulovou energii:

$$M_{x,y}^{(\text{sample}, \text{set})} = \begin{cases} E_{x,y} > 0, & \text{pokud je pixel } (x, y) \text{ uveden v } \text{entries}, \\ 0, & \text{jinak.} \end{cases}$$

Souřadnice `x` a `y` jsou celočíselné indexy v rozsahu 0 až 255. Hodnota `energy` je skalár – kalibrovaná energie v dané detektorové buňce. Nejde tedy o obraz s více barevnými kanály, ale o fyzikální

mapu depozic v pravidelné mřížce. To je z pohledu strojového učení velmi důležité: “pixel” zde není vizuální texel, ale **detektorový hit nebo buněčná depozice**.

Napříč celým dumpem je 187 771 aktivních pixelů. Energie v aktivním pixelu je vždy kladná; minimum je 2.52, medián 18.87, 99. percentil 459.55 a maximum 2246.59. Souřadnice se v rámci jedné matice nikdy neduplikují, takže každý záznam je skutečně standardní řádká matice, nikoli multiset hitů na stejné buňce. Typický snímek je tvořen směsí izolovaných bodových depozit, krátkých lineárních stop a malých kompaktních shluků. To je přesně ten typ morfologie, kde je rozumné kombinovat lokaci, tvar, energii a případně čas.


1.4 Statistický profil dumpu

Z dodaného `matrix_dump_0001.zip` jsem automaticky naparsoval 198 záznamů. Základní statistiky shrnuje tabulka 2. Většina matic je velmi řídká; medián nenulových prvků je 1154.5 z celkových 65536 buněk, což odpovídá zhruba 1.76 % aktivních pixelů. Průměrná obsazenost přes celý dump je 1.45 %, tedy přibližně 98.55 % obrazu je nulových. To je hlavní argument proti slepému používání velkých hustých CNN na celé snímky.

Tabulka 2: Shrnutí naparsovaného dumpu `matrix_dump_0001.zip`.


Velikost / statistika	Hodnota
Počet matic	198
Počet unikátních <code>sample</code>	40
Rozsah <code>sample</code>	78 až 117
Krok indexu <code>sample</code>	1
Krok <code>acq_unix</code> mezi sousedními <code>sample</code>	2 s
Pokrytá délka sekvence podle <code>acq_unix</code>	78 s
Rozměr matice	256 × 256
Matice na <code>sample</code> (min / medián / průměr / max)	1 / 5 / 4.95 / 6
Typické hodnoty <code>set_index</code>	1 až 5; hodnota 6 jen v pěti blocích
Počet nenulových buněk (min / medián / průměr / max)	3 / 1154.5 / 948.3 / 1736
Celkový počet nenulových buněk v dumpu	187771
Průměrná obsazenost	1.45 %
Medián obsazenosti	1.76 %
Počet matic s <code>nnz < 100</code>	34
Součet energie na matici (min / medián / max)	71.9 / 74687.3 / 117503.0
Energie v aktivním pixelu (min / medián / q99 / max)	2.52 / 18.87 / 459.55 / 2246.59
<code>hw_t0_ns</code> (min / medián / max)	1634 / 1008425 / 4243614
<code>hw_t_proc_ns</code> (min / medián / max)	206289331 / 249274857 / 249997164

Souhrn naparsovaného dumpu matrix_dump_0001.zip



Obrázek 2: Levá část: rozdělení počtu nenulových pixelů na matici. Pravá část: průměrný součet energie pro jednotlivé hodnoty `sample`. Je vidět, že dump obsahuje jak téměř prázdné rámce, tak hustší snímky s velkým počtem menších depozit.

Čtyři reprezentativní matice z dodaného dumpu



Obrázek 3: Čtyři ukázkové matice přímo z dodaného dumpu. Z hlediska morfologie je patrná směs izolovaných bodových depozit, krátkých lineárních stop a lokálně kompaktních shluků s výrazným energetickým maximem.


1.5 Co ukazují přiložené screenshoty

Screenshoty raw/DBSCAN jsou užitečné, protože zviditelňují současný pracovní postup i jeho limity. Například sjednocení rámců 89–96 obsahuje 8808 hitů a po DBSCANu dává 525 clusterů a 357 bodů označených jako šum. Jednotlivé snímky 67 a 176 mají kolem 1000–1300 hitů a zhruba 60–70 clusterů. Z obrazů je zřejmé, že se v datech vyskytují jak téměř bodové depozice, tak krátké lineární stopy a malé překryvy.

Raw vs. DBSCAN: přiložené screenshots z aktuální pipeline

Sjednocení rámců 89-96


Frames selected	Matrix size	Total hits (nHz sum)	Total energy sum
8	256 x 256	8,808	570,335.18



Frames selected	Matrix size	Clusters (sum over frames)	Clustered points
8	256 x 256	525	8,451


Noise points: 357

DBSCAN params: eps=1.5, min_samples=3



Jednotlivý rámeček 176


Frames selected	Matrix size	Total hits (nHz sum)	Total energy sum
1	256 x 256	1,074	71,794.49



Frames selected	Matrix size	Clusters (sum over frames)	Clustered points
1	256 x 256	61	1,018


Noise points: 56

DBSCAN params: eps=1.5, min_samples=3



Jednotlivý rámeček 67


Frames selected	Matrix size	Total hits (nHz sum)	Total energy sum
1	256 x 256	1,268	77,220.03



Frames selected	Matrix size	Clusters (sum over frames)	Clustered points
1	256 x 256	70	1,218

Noise points: 50

DBSCAN params: eps=1.5, min_samples=3



Obrázek 4: Přiložené screenshots raw zobrazení a výstupu DBSCANu. Tyto obrázky dobře ilustrují, že současný klastrovací postup už v praxi funguje jako detektor kandidátů, ale zároveň je závislý na globální volbě `eps` a `min_samples` a ignoruje většinu kontextu, který by šel neuronově vytěžit.

2 Co z dat vlastně chceme vyrobit / určit

Samotný dump ještě neobsahuje “klasifikaci částic”; obsahuje pouze měřená data. Aby byl projekt dobře definovaný, je potřeba oddělit několik vrstev výstupu. Jinak snadno vznikne zmatek mezi tím, co je přímo měřená depozice v pixelu, co je rekonstruovaný cluster a co je už fyzikální interpretace. U těchto dat je velmi užitečné uvažovat následující posloupnost:

1. **P1 – čištění a hit filtering:** rozhodnout, které aktivní pixely jsou fyzikálně relevantní signál a které jsou šum nebo artefakt.
2. **P2 – clustering / instance segmentace:** určit, které pixely patří k sobě a tvoří jednu depozici, stopu nebo spršku.
3. **P3 – klasifikace objektu:** každému clusteru nebo stopě přiřadit morfologickou nebo fyzikální třídu a důvěru.
4. **P4 – asociace přes čas nebo více pohledů:** rozhodnout, které objekty v různých `set_index` nebo sousedních `sample` patří k témuž fyzikálnímu objektu.
5. **P5 – sample/event-level souhrn:** ze všech výše uvedených kroků vytvořit počty, spektra, rate estimate, trigger nebo anomální skóre.

V současném workflow, které už používá DBSCAN, je implicitně řešen hlavně krok P2. Jakmile se řekne “klasifikace částic”, je ale potřeba doplnit i P3 a ujasnit, zda výstupem má být *morfologická třída* (např. bodový deposit, krátká stopa, dlouhá stopa, kompaktní sprška, překryv, šum) nebo *fyzikální druh částice*. To jsou dvě odlišné úlohy; druhá z nich obvykle vyžaduje víc kontextu než jen jednu 2D projekci.

Tabulka 3: Jaké produkty lze z dat rozumně vyrábět a co k nim potřebujete.

Krok	Jednotka	Co je přímý výstup	Jaká pravda / anotace je potřeba
P1	aktivní pixel / hit	signal vs. šum, případně váha nebo maska	hit-level labels, simulace, nebo konzervativní heuristiky
P2	množina hitů v rámci jednoho <code>sample</code> a <code>set_index</code>	cluster ID pro každý hit, případně instance maska	instance-level truth nebo kvalitní baseline clustering
P3	cluster / stopa / sprška	třída objektu + confidence + případně regrese energie a polohy	cluster-level třídy; pro fyzikální PID typicky simulace nebo ruční anotace
P4	dvojice či sada objektů napříč rámci	linky mezi view nebo časem, tracklet, sjednocený objekt	identita objektu přes více pohledů či časové bloky
P5	celý <code>sample</code> nebo celý běh	počty objektů, energetická spektra, trigger score, anomaly score	event-level labels nebo unsupervised cíl

2.1 Doporučený první cíl projektu

Pro přiložený dump a současné screenshoty je nejrozumnější první praktická formulace úlohy:

aktivní pixely $\rightarrow$ *cluster candidate (P2)* $\rightarrow$ *cluster-level klasifikace a confidence (P3)*.

Tato formulace je silná z několika důvodů. Za prvé navazuje přímo na to, co už dnes děláte pomocí DBSCANu. Za druhé nevyžaduje hned řešit plně end-to-end rekonstrukci na hit-level pravdě. Za třetí vám dává použitelný produkt už v první etapě: pro každý cluster dostanete nejen jeho hranici nebo identitu, ale i **třídu, důvěru a sadu fyzikálně smysluplných atributů**. A konečně je to výstup, který lze později rozšířit na P4 a P5 bez toho, aby se musela vyhodit celá pipeline.

Doporučený první deliverable

Pro každý objekt vracet minimálně: `sample`, `set_index`, `cluster_id`, seznam nebo masku hitů, celkovou energii, velikost, excentricitu, odhadovanou třídu, confidence a případně flag “nejistý / out-of-distribution”. Tento formát je vhodný jak pro online analýzu, tak pro pozdější fyzikální validaci.

2.2 Morfologická třída versus fyzikální druh částice

Z aktuálního dumpu samotného nelze přímo vyčíst ground truth fyzikálního druhu částice. Proto doporučuji rozlišit dva režimy:

- **Morfologická klasifikace.** Síť se učí rozpoznávat tvarové a energetické typy objektů: izolovaný bodový deposit, krátká stopa, dlouhá stopa, sprška, překryv, šum. To je realistické i bez plné simulace a často je to nejlepší první mezikrok.
- **Fyzikální PID.** Síť se učí mapovat rekonstruovaný objekt na fyzikální hypotézu částice. To je silnější cíl, ale typicky vyžaduje simulaci, beam metadata, geometrii detektoru nebo další detektorové kanály.

Jinými slovy: pokud v této fázi nemáte spolehlivou externí pravdu, je bezpečnější začít morfologickou taxonomií a teprve potom ji mapovat na fyzikální interpretaci. Tím se výrazně sníží riziko, že bude model přeučený na heuristické “částicové” štítky, které ve skutečnosti popisují jen tvar v 2D projekci.

2.3 Odkud vezmou štítky pravdu

Samotný dodaný dump fyzikální třídy částic neobsahuje. Máte tedy v zásadě čtyři možnosti:

- **Simulace s Monte Carlo truth.** To je pro supervised trénink nejlepší varianta a prakticky nutnost, pokud chcete jít cestou object condensation nebo hit-level segmentace.
- **Ruční anotace malého počtu clusterů.** Vhodné pro pilotní cluster classifier a pro definici morfologických tříd.
- **Vysokodůvěrné heuristiky.** Například extrémně kompaktní, izolované clustery jako pseudo-štítky pro “bodový deposit”, dlouhé lineární útvary pro “stopu” apod. To je užitečné pro bootstrap, ale ne jako finální ground truth.
- **Samoučené předtrénování.** Nejprve se síť naučí reprezentaci bez štítků, teprve potom se malý klasifikační head doučí na omezené anotaci [Young et al., 2025, Young and Terao, 2025, Park et al., 2025].

Velmi důležité je i to, že některé částice nemusí být z jedné 2D matice spolehlivě rozlišitelné jen podle tvaru. Pokud chcete jít až na fyzikální identifikaci typu částice, je výhodné přidat čas, více pohledů a případně další detektorové kontexty. Pokud taková informace k dispozici není, doporučuji zavést nejprve morfologické třídy a teprve následně je mapovat na fyzikální hypotézy.

3 Proč samotný DBSCAN nestačí, ale je stále užitečný

V terminologii sekce 2 řeší DBSCAN především krok P2, tedy clustering nebo instance segmentaci aktivních hitů. Sám o sobě ale neřeší P3, tj. klasifikaci objektu, a už vůbec ne P4, tedy asociaci přes čas nebo více paralelních pohledů. Jako současný baseline je přesto rozumný: umí najít clustery libovolného tvaru, dobře pracuje s izolovanými body a je interpretovatelný [Ester et al., 1996]. V kontextu vašich dat má ale několik strukturálních limitů:

- **Globální hustotní předpoklad.** Jedna volba `eps` a `min_samples` musí fungovat pro bodové depozity, krátké stopy i hustší shluky.
- **Energie a čas nejsou přirozeně součástí modelu.** Lze je přidat do metriky nebo následné klasifikace, ale DBSCAN se je sám nenaučí využívat adaptivně.
- **Překryvy a proměnlivá lokální hustota.** Tam DBSCAN typicky mergeuje nebo oversplittuje.
- **Agregace v čase.** Pokud se rámce jen sečtou, ztratí se pořadí a do jednoho obrazu se promítnou procesy s různou časovou strukturou.

To ale neznamená, že je třeba DBSCAN zahodit. Naopak:

- Je vhodný jako **interpretable baseline**.
- Je vhodný jako **region proposal generator** pro klasifikaci clusterů.
- Je vhodný jako **zdroj pseudo-štítků** nebo vysokodůvěrných negativních příkladů.
- Pokud chcete dočasně využít i čas, lze jako mezikrok vyzkoušet prostorově-časový variantní baseline typu ST-DBSCAN [Birant and Kut, 2007].

Dobré praktické pravidlo je tedy: **DBSCAN ponechat jako rychlý bootstrap, ale nebrat jej jako konečný rekonstrukční model.**

4 Možné neuronové přístupy

4.1 Nejrychlejší baseline: DBSCAN + klasifikátor clusterů

Toto je nejprímější implementace pipeline $P2 \rightarrow P3$ a zároveň nejrychlejší cesta k prvnímu použitelnému systému. Prakticky může vypadat takto:

1. raw matice $\rightarrow$ základní thresholding / denoising,
2. DBSCAN $\rightarrow$ kandidátní clustery,
3. pro každý cluster vytvořit ořez (*crop*) nebo seznam hitů,
4. klasifikátor vrátí třídu clusteru a případně jeho důvěru.

Takový klasifikátor může mít dvě větve:

- **obrazovou větev:** malý CNN nad ořezem clusteru, typicky 32×32 až 64×64 ,
- **tabulkovou větev:** skalární rysy jako celková energie, maximum, excentricita, délka skeletonu, počet hitů, momenty tvaru, `hw_t0_ns`, `hw_t_proc_ns`, `set_index`.

Výhoda je zřejmá: jde o rychlý, levný a velmi interpretovatelný systém. Nevýhoda je, že úspěch je limitován kvalitou DBSCAN clusterů. Jakmile se cluster rozdělí nebo slije špatně, klasifikátor to už typicky nezachrání.

4.2 Sparse CNN a U-Net nad celým snímkem

Jestliže chcete zůstat u mřížkové reprezentace, ale nechcete plýtvat výpočtem na nulových pixelech, dává smysl sparse konvoluční síť. Základní teoretický i praktický rámec vytvořily *submanifold sparse convolutions* a knihovna Minkowski Engine [Graham and van der Maaten, 2017, Choy et al., 2019]. V HEP a neutrinové fyzice jsou sparse U-Net a sparse ResNet běžným základem rekonstrukčních řetězců [Drielsma et al., 2021].

Tento směr je vhodný zejména tehdy, pokud:

- geometrie je opravdu pravidelná mřížka a lokální sousedství má fyzikální smysl,
- chcete dělat hit-level segmentaci nebo denoising,
- chcete zachovat celosnímkový kontext bez explicitního DBSCAN kroku.

Váš případ tomu odpovídá částečně. Pro jeden samotný snímek 256×256 není husté CNN ještě výpočetně nemožné. Jakmile ale budete chtít přidat více rámců, více pohledů nebo dělat plně end-to-end segmentaci, sparse CNN začne být výrazně výhodnější.

4.3 Point-set a grafové modely

Pro vaše data je to podle mého názoru **nejlepší střednědobý kompromis**. Nenulové body se přirozeně zapíší jako množina

$$\mathcal{H} = \{(x_i, y_i, E_i, t_i, \Delta t_i, s_i)\}_{i=1}^N,$$

kde s_i může nést například `set_index`. Síť pak pracuje jen nad aktivními hity. Tento směr je velmi blízký tomu, co dnes dělají moderní GNN v rekonstrukci částic [Qasim et al., 2019, Shlomi et al., 2021, Thais et al., 2022].

Prakticky lze použít například:

- **GravNet / GarNet** pro učení latentního sousedství přímo z dat [Qasim et al., 2019],
- **EdgeConv/ParticleNet-style modely** tam, kde je výhodné dynamicky přebudovávat graf [Qu and Gouskos, 2020],
- **set/point transformers** tam, kde je klíčové modelovat dlouhodobé vazby a více pohledů [Qu et al., 2022, Robles et al., 2025].

Hlavní výhody:

- reprezentace je **přímo sparse**,
- počet hitů se může měnit snímek od snímku,
- je přirozené připojit energii, čas i kategorické metadata,
- lze modelovat i více pohledů nebo více matic se stejným `sample`.

4.4 Object condensation: naučené klastrování i klasifikace v jednom kroku

Pokud je cílem nahradit DBSCAN něčím skutečně silnějším, pak je nejrelevantnější dnešní směr **object condensation** [Kieseler, 2020]. Síť pro každý hit predikuje:

- latentní souřadnice v naučeném prostoru,
- “condensation” nebo “beta” skóre, tj. pravděpodobnost, že hit reprezentuje centrum objektu,

- případně i klasifikační a regresní hlavy.

Výsledek je velmi atraktivní: v jednom kroku dostanete *instance segmentaci*, tedy přiřazení hitů k objektům, i *klasifikaci objektů*. Tento přístup byl úspěšně nasazen například pro CMS HGCAL [Qasim et al., 2021], velmi recentně pro CLAS12 calorimetr [Matousek and Vossen, 2025], a jako součást nejnovějších end-to-end hit-based rekonstrukcí na budoucích urychlovačích [Garcia et al., 2026].

Nevýhoda je jasná: potřebujete hit-level nebo alespoň instance-level ground truth. Bez simulace nebo pečlivé anotace je trénink takového modelu obtížný.

4.5 Samoučené předtrénování a foundation-model směr

Když je mnoho neoznačených dat a málo štítků, je stále relevantnější nejprve naučit obecnou reprezentaci detektorových dat a teprve potom jemně doladit malý klasifikátor. Pro sparse detektorová data se v letech 2025–2026 objevilo několik velmi silných prací: masked point modeling v PoLAR-MAE [Young et al., 2025], samodistilační reprezentace Panda [Young and Terao, 2025], širší foundation-model linie FM4NPP [Park et al., 2025] a přehledový článek o foundation modelech v HEP [Hallin, 2025].

Tento směr bych pro váš projekt nevzal jako první implementaci, ale jako **strategii pro druhou fázi**, pokud:

- nasbíráte velký archiv neoznačených snímků,
- ruční anotace bude drahá,
- budete chtít model přenášet mezi běhy, energiemi nebo detektory.

Tabulka 4: Srovnání hlavních rodin modelů pro vaše data.

Rodina	Co umí dobře	Nevýhoda	Doporučení pro váš případ
DBSCAN + cluster classifier	rychlý baseline, interpretace, málo labelů	závisí na kvalitě DBSCANu	ano, jako první produkční baseline
Sparse CNN / U-Net	hit-level segmentace, mřížkový kontext, snadná 3D/4D generalizace	víc engineeringu než jednoduchý CNN crop model	ano, pokud chcete full-frame segmentaci
Point-set / GNN	přirozená práce se sparzitou, proměnný počet hitů, snadné přidání času a metadat	potřeba grafu nebo sousednosti	ano, nejsilnější střednědobá volba
Object condensation	clustering i klasifikace v jednom kroku, neznámý počet objektů	potřebuje kvalitní truth, složitější trénink	ano, pokud máte simulaci a chcete nahradit DBSCAN
SSL / foundation model	šetří labely, dobrý přenos mezi úlohami	vyšší infra náročnost, stále rychle se vyvíjí	až druhá fáze projektu

5 Jak bych s tím prakticky postupoval

5.1 Doporučená reprezentace vstupu

U každého aktivního hitu bych vytvářel minimálně tyto rysy:

$$\mathbf{h}_i = \left[\frac{x_i}{255}, \frac{y_i}{255}, \log(1 + E_i), \frac{E_i}{\sum_j E_j + \varepsilon}, \text{set_index}, \tilde{t}_0, \widetilde{\Delta t} \right].$$

Zde $\tilde{t}_0$ a $\widetilde{\Delta t}$ jsou normalizované verze `hw_t0_ns` a `hw_t_proc_ns`. Pokud budete slučovat více rámců, doporučuji **nepoužívat pouhý součet**, ale přidat:

- **index rámce** jako další diskretní nebo spojitý rys,
- nebo vytvořit 3D sparse tensor (x, y, k) , kde k je index rámce,
- nebo pracovat se sjednocenou množinou hitů a nechat síť rozhodnout, co je časově související.

Součet přes čas je vhodný jen jako baseline. Jakmile čas zahodíte, síť už nikdy nezjistí, zda dva podobné depozity vznikly současně nebo s posunem v rámci intervalu.

5.2 Referenční architektura, kterou bych stavěl jako první

S ohledem na definici úlohy v sekci 2 bych paralelně stavěl dva modely, které cílí na odlišnou úroveň problému:

Model A: DBSCAN + point-set classifier (pipeline P2 → P3).

1. DBSCAN vytvoří kandidátní clustery.
2. Z každého clusteru se vezmou všechny hity a jejich znaky.
3. Nad hity clusteru se postaví malý k NN graf (např. $k = 12$ až 16).
4. Backbone: 4 až 6 bloků typu GravNet nebo EdgeConv, šířky 64–128 kanálů.
5. Global pooling + klasifikační hlava.
6. Volitelně druhá hlava na **puritu clusteru** nebo **důvěru**, aby síť uměla říct, že cluster je podezřele sloučený nebo rozdělený.

Model B: full-frame object condensation (spojené P2 + P3, s výhledem na P4).

1. Vstupem jsou všechny aktivní hity ve snímku nebo ve více rámcích.
2. Backbone: point-set/GNN encoder nebo sparse U-Net.
3. Výstupy pro každý hit: latentní souřadnice, beta skóre, class logits, případně regrese energie.
4. Postprocessing: jednoduchý condensation step namísto DBSCANu.

Tento pár modelů je silný proto, že Model A rychle doručí použitelný cluster-level klasifikátor nad dnešní pipeline, zatímco Model B současně otevírá cestu k end-to-end rekonstrukci, kde se clustering i klasifikace učí společně.

5.3 Ztrátové funkce a trénink

Pokud děláte čistou klasifikaci clusterů, stačí vážená cross-entropy nebo focal loss. Pokud je silná nevyváženost tříd, focal loss bývá užitečná. Pro end-to-end rekonstrukci bych uvažoval vícesložkovou ztrátu typu

$$\mathcal{L} = \lambda_{\text{cls}} \mathcal{L}_{\text{CE}} + \lambda_{\text{seg}} \mathcal{L}_{\text{OC}} + \lambda_{\text{reg}} \mathcal{L}_{\text{Huber}},$$

kde $\mathcal{L}_{\text{OC}}$ je object-condensation ztráta [Kieseler, 2020].

Praktické tipy:

- **Rozdělení dat dělat po sample nebo po časových blocích**, nikoli náhodně po hitech. Jinak hrozí leakage mezi tréninkem a testem.
- **Normalizaci energie dělat konzistentně po kalibračním období**, ne po jednotlivých clusterech tak, aby se ztratila absolutní škála.
- **Augmentace pouze fyzikálně smysluplné**: translace, zrcadlení, malé jittery energie, hit dropout simulující neúčinnost, přídatný šum. Rotace pouze pokud ji dovoluje geometrie detektoru.
- **Důsledně vyhodnocovat nejistotu**. V produkci je užitečné mít kalibrovanou pravděpodobnost a mechanismus pro odmítnutí neznámých případů.

5.4 Co měřit, aby model byl opravdu užitečný

U klasifikace clusterů nestačí pouze accuracy. Doporučuji minimálně:

- **macro F1** a **per-class recall/precision**,
- **confusion matrix** po bins v energii a velikosti clusteru,
- **cluster purity** a **cluster efficiency**,
- **merge/split rate** vůči truth segmentaci,
- **energy-weighted IoU** pro párování truth a predikovaných objektů [Qasim et al., 2021],
- latenci a paměť při inferenci.

Pro vědecké použití je důležité přidat i **fyzikální validaci**: jak se chyba klasifikace mění s energií, polohou v detektoru, obsazeností rámce a časovým intervalem.

Největší rizika projektu

- **Nejasná definice třídy**. “Typ částice” může být v jedné 2D projekci jen částečně identifikovatelný.
- **Sim-to-real gap**. Pokud se bude trénovat na simulaci, je potřeba hlídat posun vůči reálným datům.
- **Leakage v časově sousedních sample**. Blízké rámce nejsou nezávislé.
- **Ztráta časové informace při agregaci**. Sečtení rámců je pohodlné, ale často suboptimální.

6 Zasazení do současného stavu oboru

Současný SOTA v rekonstrukci částic z detektorových hitů se zhruba dělí do čtyř linií.

6.1 1. Sparse backbones a end-to-end rekonstrukční řetězce

První důležitá linie říká: *zachovat sparsity co nejdéle*. To začíná u submanifold sparse convolutions [Graham and van der Maaten, 2017] a u Minkowski Engine pro vyšší dimenze a čas [Choy et al., 2019]. V neutrinové fyzice se tento přístup propal do end-to-end řetězců typu SPINE, kde sparse CNN tvoří nízkoúrovňový backbone a následné GNN skládají částicovou superstrukturu [Drielsma et al., 2021]. Pro vaše data je to relevantní zejména tehdy, pokud chcete dělat hit-level segmentaci nad celým snímkem nebo nad několika po sobě jdoucími rámci.

6.2 2. Grafové a point-set modely pro irregular detector geometry

Druhá linie vychází z toho, že detektorová data přirozeně tvoří množiny a grafy. GravNet a GarNet ukázaly, že lze učením latentní geometrie dobře řešit clustering ve vysoce granularních kalorimetrech [Qasim et al., 2019]. Přehledové práce o GNN v částicové fyzice dnes považují grafové modely za jednu z hlavních architektur pro rekonstrukci, tagging i generování [Shlomi et al., 2021, Thais et al., 2022]. V navazujících detektorových aplikacích vidíme tuto linii ve fotonové rekonstrukci pro Belle II [Wemmer et al., 2023], v NuGraph2 pro LArTPC [Hewes et al., 2024] a v end-to-end multi-track rekonstrukci pro Belle II [Reuter et al., 2025].

Pro váš problém je tato linie velmi relevantní, protože:

- data jsou silně sparse,
- počet hitů se mění event od eventu,
- čas a metadata se dají připojit jako přirozené rysy uzlů,
- více matic se stejným `sample` lze modelovat jako více pohledů.

6.3 3. Naučené klastrování: object condensation a jeho potomci

Třetí linie je dnes asi nejzajímavější tam, kde je třeba *najít neznámý počet objektů*. Práce Kieseler [2020] formalizovala object condensation jako obecný framework pro grid-free multi-object reconstruction v detektorových datech. Na to navázala řada konkrétních aplikací. Pro CMS HGCAL bylo ukázáno, že GravNet + object condensation umí v jednom kroku clustering, klasifikaci i regresi energie a polohy [Qasim et al., 2021]. V roce 2025 se stejná idea objevuje u CLAS12, kde kombinace GravNetu, transformer encoderu a object condensation výrazně zvyšuje důvěryhodnost neutronových a fotonových clusterů [Matousek and Vossen, 2025]. Na úplné špičce pak stojí velmi recentní práce pro budoucí urychlovače, která spojuje geometric algebra transformer s object condensation přímo na hit-level vstupu a zlepšuje rekonstrukční efektivitu i falešnou míru oproti pravidlovému baseline [Garcia et al., 2026].

Z hlediska vašich dat je to **nejbližší plnému nahrazení DBSCANu**.

6.4 4. Transformery, unified particle flow a foundation models

Čtvrtá linie je novější a více experimentální. V HEP nejprve silně zafungovaly set-based a transformerové architektury v příbuzných úlohách, například ParticleNet a Particle Transformer v jet taggingu [Qu and Gouskos, 2020, Qu et al., 2022]. Pro rekonstrukci detektorových hitů se tento trend přesouvá k point-set transformerům na sparse maticích [Robles et al., 2025], k unified particle-flow transformerům typu GLOW [Kobylianskii et al., 2025] a k self-supervised nebo foundation-model přístupům [Young et al., 2025, Young and Terao, 2025, Park et al., 2025, Giroux and Fanelli, 2025, Hallin, 2025].

Tento směr je důležitý hlavně strategicky:

- když je hodně neoznačených dat a málo truth labelů,
- když chcete reprezentaci přenášet mezi úlohami,
- když nechcete pro každý subtask trénovat samostatný model od nuly.

Je ale poctivé říci, že pro *první produkční systém* nad vaším konkrétním dumpem bych foundation-model přístup ještě nebral jako první krok. Je to spíš střednědobá investice.

Tabulka 5: Stručné zasazení do SOTA literatury.

Směr	Reprezentativní práce	Co plyne pro tento projekt
Sparse convolutions	Graham and van der Maaten [2017], Choy et al. [2019], Drielsma et al. [2021]	full-frame segmentace je realistická bez převodu na husté 3D/4D tenzory
Graph / point-set reconstruction	Qasim et al. [2019], Wemmer et al. [2023], Hewes et al. [2024], Reuter et al. [2025]	aktivní hity lze modelovat přímo jako body/uzly s energií a časem
Learned clustering	Kieseler [2020], Qasim et al. [2021], Matousek and Vossen [2025], Garcia et al. [2026]	DBSCAN lze nahradit sítí, která se clustering naučí z truth labelů
Transformer / SSL / foundation	Robles et al. [2025], Kobylanskii et al. [2025], Young et al. [2025], Young and Terao [2025], Park et al. [2025]	nejslibnější směr pro label-efficient učení a dlouhodobý rozvoj

7 Doporučený plán po etapách

Etapa 1: rychlý baseline (1 až 2 týdny čisté implementace).

- zachovat současný DBSCAN,
- vytvořit dataset clusterů a jejich metadat,
- natrénovat malý CNN nebo point-set classifier,
- zavést metriky: macro F1, purity, merge/split rate.

Etapa 2: silný model nad sparse reprezentací.

- point-set/GNN model nad všemi hity nebo nad DBSCAN clusterem,
- využít `set_index` a časová metadata jako vstupní znaky,
- otestovat, zda je lepší per-frame inference nebo více-rámcový model.

Etapa 3: learned clustering.

- připravit hit-level truth ze simulace,
- přejít na object condensation nebo ekvivalentní instance segmentation,
- vyhodnotit, kdy lze DBSCAN úplně vypnout.

Etapa 4: self-supervised pretraining.

- nashromáždit velký archiv neoznačených dat,
- předtrénovat sparse encoder nebo point-set encoder,
- doladit pouze malou klasifikační hlavu na omezené anotaci.

8 Závěr

Pro váš konkrétní typ dat a pro cíle formulované v sekci 2 bych doporučil tento rozhodovací rámec:

- **Pokud chcete rychle funkční první deliverable:** nechte DBSCAN jako řešení P2 a postavte nad ním cluster-level klasifikátor pro P3.
- **Pokud chcete nejlepší poměr výkon / složitost:** point-set nebo GNN model nad aktivními hity, který přirozeně pojme lokaci, energii, čas i `set_index`.
- **Pokud chcete nahradit DBSCAN a jít směrem SOTA:** object condensation nebo příbuzný learned-clustering model, který spojí P2 a P3 do jednoho kroku.
- **Pokud zatím nemáte fyzikální truth:** začněte morfologickými třídami a teprve potom přejděte na fyzikální PID.
- **Pokud čekáte málo štítků a hodně neoznačených dat:** self-supervised pretraining a teprve pak fine-tuning.

Nejdůležitější praktické sdělení je jednoduché: **u takto řídkých dat se vyplatí pracovat se seznamem aktivních hitů, nikoli s hustým obrazem, a nezhazovat časovou osu pouhou sumací rámců.** Stejně důležité ale je nezaměňovat měření s produktem: dump obsahuje energetické hity, zatímco klasifikace částice je až výstup rekonstrukčního řetězce, který musí nejprve vyřešit alespoň clustering a často i asociaci přes čas nebo více pohledů. Právě zde neuronové sítě dávají smysl: umí se naučit využít energii, tvar, lokaci i čas současně, zatímco ruční hustotní klastrování pracuje jen s velmi omezenou metrikou.

Reference

- Jan Kieseler. Object condensation: One-stage grid-free multi-object reconstruction in physics detectors, graph and image data. *European Physical Journal C*, 80(9):886, 2020. doi: 10.1140/epjc/s10052-020-08461-2. URL <https://arxiv.org/abs/2002.03605>.
- Shah Rukh Qasim, Kenneth Long, Jan Kieseler, Maurizio Pierini, and Raheel Nawaz. Multi-particle reconstruction in the high granularity calorimeter using object condensation and graph neural networks. *arXiv preprint arXiv:2106.01832*, 2021. doi: 10.48550/arXiv.2106.01832. URL <https://arxiv.org/abs/2106.01832>.
- Dolores Garcia, Lena Herrmann, Gregor Krzmann, and Michele Selvaggi. End-to-end event reconstruction for precision physics at future colliders. *arXiv preprint arXiv:2603.04084*, 2026. URL <https://arxiv.org/abs/2603.04084>.
- Sam Young, Yeon-jae Jwa, and Kazuhiro Terao. Particle trajectory representation learning with masked point modeling. *arXiv preprint arXiv:2502.02558*, 2025. doi: 10.48550/arXiv.2502.02558. URL <https://arxiv.org/abs/2502.02558>.

- Samuel Young and Kazuhiro Terao. Panda: Self-distillation of reusable sensor-level representations for high energy physics. *arXiv preprint arXiv:2512.01324*, 2025. doi: 10.48550/arXiv.2512.01324. URL <https://arxiv.org/abs/2512.01324>.
- David Park, Shuhang Li, Yi Huang, Xihai Luo, Haiwang Yu, Yeonju Go, Christopher Pinkenburg, Yuewei Lin, Shinjae Yoo, Joseph Osborn, Jin Huang, and Yihui Ren. Fm4npp: A scaling foundation model for nuclear and particle physics. *arXiv preprint arXiv:2508.14087*, 2025. doi: 10.48550/arXiv.2508.14087. URL <https://arxiv.org/abs/2508.14087>.
- Martin Ester, Hans-Peter Kriegel, Jörg Sander, and Xiaowei Xu. A density-based algorithm for discovering clusters in large spatial databases with noise. In *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining (KDD)*, pages 226–231, 1996.
- Derya Birant and Alp Kut. St-dbscan: An algorithm for clustering spatial-temporal data. *Data & Knowledge Engineering*, 60(1):208–221, 2007. doi: 10.1016/j.datak.2006.01.013.
- Benjamin Graham and Laurens van der Maaten. Submanifold sparse convolutional networks. *arXiv preprint arXiv:1706.01307*, 2017. doi: 10.48550/arXiv.1706.01307. URL <https://arxiv.org/abs/1706.01307>.
- Christopher Choy, JunYoung Gwak, and Silvio Savarese. 4d spatio-temporal convnets: Minkowski convolutional neural networks. *arXiv preprint arXiv:1904.08755*, 2019. doi: 10.48550/arXiv.1904.08755. URL <https://arxiv.org/abs/1904.08755>.
- Francois Drielsma, Kazuhiro Terao, Laura Dominé, and Dae Heun Koh. Scalable, end-to-end, deep-learning-based data reconstruction chain for particle imaging detectors. *arXiv preprint arXiv:2102.01033*, 2021. doi: 10.48550/arXiv.2102.01033. URL <https://arxiv.org/abs/2102.01033>.
- Shah Rukh Qasim, Jan Kieseler, Yutaro Iiyama, and Maurizio Pierini. Learning representations of irregular particle-detector geometry with distance-weighted graph networks. *European Physical Journal C*, 79(7):608, 2019. doi: 10.1140/epjc/s10052-019-7113-9. URL <https://arxiv.org/abs/1902.07987>.
- Jonathan Shlomi, Peter Battaglia, and Jean-Roch Vlimant. Graph neural networks in particle physics. *Machine Learning: Science and Technology*, 2(2):021001, 2021. doi: 10.1088/2632-2153/abbf9a. URL <https://arxiv.org/abs/2007.13681>.
- Savannah Thais, Paolo Calafiura, Grigorios Chachamis, Gage DeZoort, Javier Duarte, Sanmay Ganguly, Michael Kagan, Daniel Murnane, Mark S. Neubauer, and Kazuhiro Terao. Graph neural networks in particle physics: Implementations, innovations, and challenges. *arXiv preprint arXiv:2203.12852*, 2022. doi: 10.48550/arXiv.2203.12852. URL <https://arxiv.org/abs/2203.12852>.
- Huilin Qu and Loukas Gouskos. Particlenet: Jet tagging via particle clouds. *Physical Review D*, 101(5):056019, 2020. doi: 10.1103/PhysRevD.101.056019. URL <https://arxiv.org/abs/1902.08570>.
- Huilin Qu, Congqiao Li, and Sitian Qian. Particle transformer for jet tagging. *Proceedings of Machine Learning Research*, 162:18281–18292, 2022. doi: 10.48550/arXiv.2202.03772. URL <https://arxiv.org/abs/2202.03772>.
- Edgar E. Robles, Alejandro Yankelevich, Wenjie Wu, Jianming Bian, and Pierre Baldi. Particle hit clustering and identification using point set transformers in liquid argon time projection chambers. *arXiv preprint arXiv:2504.08182*, 2025. doi: 10.48550/arXiv.2504.08182. URL <https://arxiv.org/abs/2504.08182>.

- Gregory Matousek and Anselm Vossen. Ai-assisted object condensation clustering for calorimeter shower reconstruction at clas12. *arXiv preprint arXiv:2503.11277*, 2025. doi: 10.48550/arXiv.2503.11277. URL <https://arxiv.org/abs/2503.11277>.
- Anna Hallin. Foundation models for high-energy physics. *arXiv preprint arXiv:2509.21434*, 2025. doi: 10.48550/arXiv.2509.21434. URL <https://arxiv.org/abs/2509.21434>.
- F. Wemmer, I. Haide, J. Eppelt, T. Ferber, et al. Photon reconstruction in the belle ii calorimeter using graph neural networks. *Computing and Software for Big Science*, 7:13, 2023. doi: 10.1007/s41781-023-00105-w. URL <https://arxiv.org/abs/2306.04179>.
- V. Hewes, Adam Aurisano, Giuseppe Cerati, Jim Kowalkowski, Claire Lee, Wei-keng Liao, Daniel Grzenda, Kaushal Gumpula, and Xiaohe Zhang. Graph neural network for neutrino physics event reconstruction. *Physical Review D*, 110(3):032008, 2024. doi: 10.1103/PhysRevD.110.032008. URL <https://arxiv.org/abs/2403.11872>.
- Lea Reuter, Giacomo De Pietro, Slavomira Stefkova, Torben Ferber, et al. End-to-end multi-track reconstruction using graph neural networks at belle ii. *Computing and Software for Big Science*, 9:6, 2025. doi: 10.1007/s41781-025-00135-6. URL <https://arxiv.org/abs/2411.13596>.
- Dmitrii Kobylanskii, Samuel Van Stroud, Kwok Yiu Wong, Max Hart, Etienne Dreyer, Eilam Gross, Gabriel Facini, and Tim Scanlon. Glow: A unified particle flow transformer. *arXiv preprint arXiv:2508.20092*, 2025. doi: 10.48550/arXiv.2508.20092. URL <https://arxiv.org/abs/2508.20092>.
- James Giroux and Cristiano Fanelli. Towards foundation models for experimental readout systems combining discrete and continuous data. *arXiv preprint arXiv:2505.08736*, 2025. doi: 10.48550/arXiv.2505.08736. URL <https://arxiv.org/abs/2505.08736>.